

☰

 d87千克 / 横梁 ▾

🔍

+



代码

问题

拉取请求

代理人

行动

项目

维基百科

更多的 ▾

安全与质量

📄

主要的 ▾

横梁 / 纸 / Traccia-Paper-v1.0.md

🔍 转到文件

T

⋮

 d87千克 添加纸质草稿

f00b907 · 1分钟前

更多编辑选项

预览

代码

责备

151 行 (103 个位置) · 5.86 KB





生的







⋮

Traccia：一个以执行为中心的、具有残差评估的 AI 代理基准测试

作者：Traccia 项目
仓库：github.com/d87skg/traccia
数据集：[vasdvae/traccia-benchmark](https://huggingface.co/datasets/vasdvae/traccia-benchmark) 来自 HuggingFace
工具：`pip install traccia-eval`

抽象的

当前的AI智能体基准测试仅评估最终输出——准确率、胜率、通过率（每次尝试成功）——而忽略了执行质量。我们提出了一种**以执行为中心的评估方法**，该方法基于智能体的完整执行轨迹而非仅仅其最终答案来评估其得分。我们引入了开源框架**Traccia .evidence**，该框架能够捕获结构化的执行轨迹，将其分解为一个四维残差向量（时间、语义、结构和恢复），并根据智能体如何处理失败（而不仅仅是是否避免失败）来对其进行评分。我们发布了一个包含27个执行轨迹的基准数据集（涵盖6个运行时环境）、一个标准化的评分函数以及一个公开排行榜。实验表明，仅基于输出的排名与基于执行的排名存在显著差异，这表明即使智能体获得了相同的答案，它们也采用了截然不同且可量化的执行策略。

主要论点

- 执行轨迹是一种一流的评估原语。**智能体在任务执行期间的行为——工具选择、故障处理、恢复策略——包含独立于最终结果的可评估结构。
- 执行质量可以通过残差分析进行量化。**一个四维残差向量（时间、语义、结构、恢复）可以捕捉到与预期执行模式的偏差，并直接用于评分。
- 仅基于输出结果的排名与基于执行结果的排名存在差异。**相同的正确性可能会掩盖执行质量上的显著差异，而这些差异是传统基准测试无法检测到的。

快速入门

```
# Install core tools
pip install traccia-guard # safety guard for agents
pip install traccia-eval  # evaluation & leaderboard

# Generate benchmark data with closed-loop execution
traccia loop run --iterations 10

# Score a dataset and view leaderboard
traccia-eval dataset.jsonl

# Load the published benchmark dataset
python -c "from datasets import load_dataset; print(load_dataset('vasdvae/traccia-bench
```



.evidence 格式

`.evidence` 是一个结构化的、经过链式验证的执行跟踪文件，打包成 ZIP 压缩包。每个压缩包包含：

- `session.json` — 任务目标、运行时间、状态
- `events.jsonl` — 按时间顺序排列的典型事件序列
- `evidence.json` — 执行证明（工具输出、日志）
- `attribution.json` — 角色责任映射
- `signature.sig` — SHA-256 哈希链完整性验证

规范事件类型将来自不同代理运行时（LangChain、CrewAI、OpenAI SDK、Claude Code、OpenHands）的输出统一到一个评估词汇表中。

残差分析与评分

我们为每个执行轨迹提取一个 4 维残差向量：

方面	它捕捉到的内容
显	事件聚类、重复时间戳、批处理
语义	工具输出中出现意外字段，模式漂移
结构	哈希链断裂，孤立事件
恢复	恢复尝试次数与错误次数之比，重试逻辑

Traccia**评分**是基于残差衍生指标的加权总和：



$$\text{Score} = 0.3 \times \text{Correctness} + 0.2 \times \text{Stability} + 0.2 \times \text{Recoverability} + 0.2 \times (1 - \text{Entropy}) + 0.1 \times \text{Efficiency}$$

该评分函数是确定性的、无需人工标记的、可重复的。

基准数据集

`vasdvae/traccia-benchmark` 包含 6 个运行时环境的 27 个执行跟踪记录 + 闭环合成数据：

运行时	范例	痕迹
朗链	工具调用	4
CrewAI	多智能体	4
自动生成	对话	3
OpenAI SDK	函数调用	3
克劳德·科德	混合操作系统	4
开放之手	完整操作系统代理	4
STG-Loop	闭环合成器	5

每个条目都包含完整的任务定义、执行轨迹、残差向量和评估分数。

排行榜

示例排行榜由以下方式生成 `traccia-eval`：



Rank	Score	Runtime	Recovery	Stability
1	0.7600	stg-loop	0.00	1.00
2	0.7267	langchain	1.33	1.00
3	0.6600	openai	1.00	1.00
...				

完整的排名可在 `leaderboard.json` 数据集文件中查看。

存储库结构



```
traccia/
├─ cli/          ← CLI entry (intercept, diagnose, loop)
├─ src/traccia/  ← core library (recorder, residual, loop, entropy)
```

— guard/	← safety guard (pip install traccia-guard)
— eval/	← traccia-eval scoring & leaderboard
— dataset/	← benchmark dataset & HF loader
— tools/	← dataset builder, leaderboard generator
— ARCHITECTURE.md	← six-layer architecture definition
— README.md	← this file

引用

如果您在研究中使用了 Traccia 的数据，请引用：

```
@software{traccia2026,  
  author   = {Traccia Project},  
  title    = {Traccia: An Execution-Centric Benchmark for AI Agents with Residual Eval},  
  year     = {2026},  
  url      = {https://github.com/d87skg/traccia}  
}
```

执照

本项目采用 Apache License 2.0 许可——详情请参阅[LICENSE文件](#)。

接触

如有任何疑问或需要合作，请在 GitHub 上提交 issue 或通过仓库联系我们。